

Visualization & EDA for Machine Learning

Практический конспект - Matplotlib - Distributions - Relations - Target - Conclusions


Главная идея: EDA - это последовательность вопросов к данным: качество, распределения, связи, target и решения перед моделированием.

Содержание

1. Зачем нужен EDA	1
2. Matplotlib basics	2
3. Histogram: форма распределения	2
4. Boxplot и IQR	2
5. Bar chart: категории	2
6. Scatter: связь двух числовых признаков	2
7. Несколько признаков	3
8. Correlation	3
9. Анализ target	3
10. Выбросы: найти, понять, решить	3
11. Полный EDA workflow	3
12. Мини-EDA одного датасета	4
13. Как формулировать выводы	4
14. Финальная шпаргалка	4
15. Что должно быть в голове	5

1. Зачем нужен EDA

Exploratory Data Analysis отвечает до моделирования на четыре вопроса: что лежит в данных, насколько им можно доверять, какие закономерности видны и что может сломать модель.



Главный принцип: График без вопроса - украшение. Сначала формулируй вопрос, затем выбирай визуализацию и записывай вывод.

2. Matplotlib basics

```
import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(7, 4))
ax.plot(x, y, marker='o')
ax.set(title='Score by hours', xlabel='Study hours', ylabel='Score')
ax.grid(alpha=0.25)
fig.tight_layout()
plt.show()
```

Работай через **fig**, **ax**: так проще строить несколько графиков, настраивать подписи и управлять размером.

3. Histogram: форма распределения

```
fig, ax = plt.subplots(figsize=(7, 4))
ax.hist(df['score'].dropna(), bins=20, edgecolor='white')
ax.set(title='Score distribution', xlabel='Score', ylabel='Count')
```

Смотри на центр, разброс, асимметрию, несколько пиков, пустые интервалы и длинные хвосты. Число `bins` меняет детализацию, поэтому проверь несколько разумных значений.

Не путай: Высокий столбец означает много наблюдений в интервале, а не большое значение признака.

4. Boxplot и IQR

```
q1 = df['score'].quantile(0.25)
q3 = df['score'].quantile(0.75)
iqr = q3 - q1
low, high = q1 - 1.5 * iqr, q3 + 1.5 * iqr
outliers = df[(df['score'] < low) | (df['score'] > high)]

plt.boxplot(df['score'].dropna(), vert=False)
```

Boxplot показывает медиану, квартильный диапазон и кандидатов в выбросы. Правило 1.5 IQR - эвристика, а не команда удалять строки.

5. Bar chart: категории

```
counts = df['city'].value_counts(dropna=False)
fig, ax = plt.subplots(figsize=(7, 4))
counts.plot.bar(ax=ax)
ax.set(title='Students by city', xlabel='City', ylabel='Count')
ax.tick_params(axis='x', rotation=30)
```

Выбор: Histogram - числовое распределение по интервалам. Bar chart - отдельные категории и их частоты.

6. Scatter: связь двух числовых признаков

```
fig, ax = plt.subplots(figsize=(7, 4))
ax.scatter(df['study_hours'], df['score'], alpha=0.55)
ax.set(xlabel='Study hours', ylabel='Score', title='Hours vs score')
```

Ищи направление связи, нелинейность, кластеры, изменение разброса и отдельные точки. **alpha** помогает увидеть плотность при наложении.

Важно: Корреляция или визуальная связь не доказывает причинность.

7. Несколько признаков

```
fig, axes = plt.subplots(1, 3, figsize=(12, 3.5))
for ax, col in zip(axes, ['age', 'study_hours', 'score']):
    ax.hist(df[col].dropna(), bins=18)
    ax.set_title(col)
fig.tight_layout()
```

Единая сетка облегчает сравнение шкал и форм распределений. Не перегружай один график: одинаковые оси полезны только для сопоставимых величин.

8. Correlation

```
num = df.select_dtypes(include='number')
corr = num.corr()

fig, ax = plt.subplots(figsize=(7, 6))
im = ax.imshow(corr, vmin=-1, vmax=1, cmap='coolwarm')
ax.set_xticks(range(len(corr)), corr.columns, rotation=45, ha='right')
ax.set_yticks(range(len(corr)), corr.columns)
fig.colorbar(im, ax=ax)
```

Коэффициент близкий к 1 означает положительную линейную связь, к -1 - отрицательную, к 0 - отсутствие заметной линейной связи.

Ограничение: `corr()` может пропустить нелинейную зависимость и быть искажён выбросами. Подтверждай важные пары scatter-графиком.

9. Анализ target

```
df['passed'].value_counts(dropna=False)
df['passed'].value_counts(normalize=True)

df.groupby('passed')['score'].agg(['count', 'mean', 'median'])
```

Для классификации проверь баланс классов и распределения признаков внутри каждого класса. Для регрессии исследуй распределение target, хвосты, нули и невозможные значения.

Leakage check: Очень сильная связь feature с target требует проверки: признак мог появиться после события или прямо кодировать ответ.

10. Выбросы: найти, понять, решить

Причина	Действие
Ошибка ввода	Исправить или пометить NaN
Другая единица измерения	Привести к общей шкале
Редкий, но реальный случай	Сохранить; оценить влияние
Артефакт сбора	Исключить по прозрачному правилу

Нельзя: Удалять точку только потому, что она находится за усами boxplot. Решение должно опираться на смысл данных.

11. Полный EDA workflow



Шаг	Результат
1. Контекст	Объект, target, единица строки
2. Качество	NaN, duplicates, dtypes, ranges
3. Один признак	Распределения и категории
4. Связи	Scatter, groups, correlation
5. Target	Баланс и условные различия
6. Итог	Наблюдение -> риск -> действие

12. Мини-EDA одного датасета

```
target = 'passed'
print(df.shape)
print(df[target].value_counts(normalize=True, dropna=False))
print(df.isna().mean().sort_values(ascending=False).head(10))

num_cols = df.select_dtypes(include='number').columns
cat_cols = df.select_dtypes(exclude='number').columns

df[num_cols].hist(figsize=(10, 7), bins=20)
plt.tight_layout()

for col in cat_cols:
    print(df[col].value_counts(dropna=False).head(10))

print(df[num_cols].corr()[target].sort_values())
```

После кода: Для каждого результата напиши 1-2 предложения: что видно, почему это важно и какое действие последует.

13. Как формулировать выводы

Слабо	Сильно
Есть пропуски	В income 18% NaN; проверим зависимость пропуска от target и заполним внутри Pipeline
Есть выбросы	Три возраста выше 100; вероятно ошибка ввода, строки проверим по источнику
Есть корреляция	Hours и score связаны умеренно положительно; scatter показывает насыщение после 20 часов
Формула: Наблюдение + число/график + интерпретация + следующее действие.	

14. Финальная шпаргалка

```
# quality
df.shape; df.info(); df.isna().mean(); df.duplicated().sum()

# distributions
df[num_cols].hist(bins=20)
df[cat_col].value_counts(dropna=False).plot.bar()
plt.boxplot(df[num_col].dropna(), vert=False)

# relations
plt.scatter(df[x_col], df[y_col], alpha=.5)
df.select_dtypes('number').corr()

# target
df[target].value_counts(normalize=True)
df.groupby(target)[num_cols].agg(['mean', 'median'])
```

15. Что должно быть в голове

EDA: question -> data quality -> distributions -> relations -> target -> conclusions

Графики: hist = distribution; boxplot = quartiles/outlier candidates; bar = categories; scatter = numeric relation

Результат: EDA заканчивается не картинками, а проверяемыми выводами и решениями для preprocessing и моделирования.